

# 기술 백서: Preference-based Multi-Objective Reinforcement Learning (Pb-MORL)

[Paper Title / Core Technology]

Preference-based Multi-Objective Reinforcement Learning

## 1. 설계 철학 및 문제 정의 (Architectural Philosophy)

기존 기술의 임계점 (Legacy Bottleneck):

- 근본 원인 (Root Cause): 기존 Multi-Objective RL (MORL)은 각 목표(Objective)들에 대한 스칼라 보상 함수(Scalar Reward Function)가 사전에 완벽하게 정의되어 있다고 가정함.
- 치명적 한계 (Critical Failure): 현실 세계의 복잡한 다목적 문제(예: 자율주행의 안전 vs 승차감 vs 속도)를 단순한 수치적 보상으로 표현하는 것은 불가능에 가까움. 잘못 설계된 보상 함수는 Reward Hacking이나 Oversimplification을 초래하여, 실제 의도와 다른 괴상한 정책을 유도함.
- 패러다임 전환 (Paradigm Shift): 본 논문은 "보상 함수 설계"라는 난제를 우회하기 위해, 인간의 선호(Preference) 데이터를 직접 활용하여 명시적인 다목적 보상 모델(Explicit Multi-Objective Reward Model)을 학습하는 Pb-MORL 프레임워크를 제안함. 이를 통해 복잡한 보상 설계 없이도 파레토 최적(Pareto Optimal) 정책을 학습할 수 있음을 증명함.

개념 시각화 (Conceptual Analogy):

> [Analogy] 요리 대회에서 심사위원이 "소금 3g, 설탕 5g"처럼 정확한 점수 기준(Reward Function)을 주는 것이 아니라, 두 요리를 먹어보고 "A가 B보다 낫다"는 선호(Preference)만 표현하면, 요리사(Agent)가 그 선호 패턴을 학습하여 최고의 요리(Optimal Policy)를 만들어내는 것과 같음.

## 2. 수학적 원리 및 분류 (Mathematical Formalism)

시스템 분류 (System Taxonomy):

- 아키텍처 유형: Preference-based Multi-Objective Reinforcement Learning (Pb-MORL)
- 알고리즘 기반: Envelope Q-Learning (EQL) + Bradley-Terry Preference Model
- 불변 특성: Pareto Optimality Guarantee (Under Condition of Consistent Preferences)

핵심 수식 및 상세 해설 (Core Formulation & Breakdown):

1. Bradley-Terry Preference Model:

$$P_{\psi}(\sigma_i > \sigma_j | w) = \frac{\exp(\sum_t \gamma^t w r_{\psi}(s_t, a_t))}{\sum_{j \in [0, 1]} \exp(\sum_t \gamma^t w r_{\psi}(s_t, a_t))}$$

- Variable Definition (변수 정의):
- $P_{\psi}$  : 학습된 보상 모델  $r_{\psi}$  를 기반으로 한 선호 확률 예측기
- $\sigma_i, \sigma_j$  : 비교 대상이 되는 두 궤적(Trajectory Segment)
- $w$ : 선호 판단의 기준이 되는 가중치 벡터 (Weight Vector).  $w \in \mathbb{R}^m, \sum w = 1$ .
- $r_{\psi}(s, a)$ : 파라미터  $\psi$  로 학습되는 명시적 다목적 보상 모델 (Vector)
- $>$ : 선호 관계 (Preferred over)
- Physical Meaning (수식의 물리적 의미):
- 두 궤적 간의 선호 확률은 각 궤적의 누적 보상(학습된 보상 모델 값)의 지수 함수적 비율로 결정된다. 즉, 학습된 보상 모델  $r_{\psi}$  의 합이 클수록 더 선호될 확률이 높게 모델링된다. 이는 선호 데이터를 통해 역으로 보상 함수를 추정할 수 있게 해주는 핵심 연결 고리이다.

## 2. Cross-Entropy Loss (Reward Learning):

$$L(\psi) = -\mathbb{E}_{(\sigma_i, \sigma_j, w, p) \sim D} [p \log P_{\psi}(\sigma_i > \sigma_j | w) + (1-p) \log P_{\psi}(\sigma_j > \sigma_i | w)]$$

- Variable Definition:
- $p$ : 실제 인간(또는 교사)의 선호 레이블 (0, 0.5, 1)
- $D$ : 수집된 선호 데이터셋
- Physical Meaning:
- 예측된 선호 확률  $P_{\psi}$  와 실제 선호  $p$  사이의 차이(엔트로피)를 최소화한다. 이를 통해 보상 모델  $r_{\psi}$  는 인간의 선호 판단 기준을 모사하게 된다.

## 3. Multi-Objective Q-Learning (Policy Optimization):

$$J(\pi) = \mathbb{E}_{w \sim D} [w \cdot Q(s, a, w)]$$

- Physical Meaning:
- 학습된 보상 모델  $r_{\psi}$  를 통해 계산된 Q 값을 최대화하는 방향으로 정책을 업데이트한다. 여기서 Q 값은 다목적 벡터이며, 가중치  $w$ 와 내적을 통해 스칼라화된 효용(Utility)을 극대화한다.

## 3. 실행 파이프라인 및 데이터 흐름 (Execution Pipeline)

입력 명세 (Trace Spec):

- Input Context: State Vector `[Batch, State\_Dim]`, Weight Vector `[Batch, Objective\_Dim]`
- 예시: `s=[10.5, 3.2]`, `w=[0.7, 0.3]` (속도 중시형)

순전파 로직 (Forward Propagation Logic):

1. Preference Query & Collection:

- Action: 에이전트가 환경과 상호작용하여 궤적 쌍  $(\sigma, \sigma')$  생성.
- Feedback: 교사(Teacher)가 가중치  $w$  하에서 선호  $p$ 를 제공.
- Data Storage: 'Buffer'  $\rightarrow (\sigma_0, \sigma_1, w, p)$

2. Reward Model Forward:

- Input: Segment  $\sigma$  (State-Action Sequence)
- Process: Neural Network  $\psi$  가 각  $(s,a)$ 에 대해 벡터 보상  $r_\psi(s,a)$  출력.
- Aggregation:  $\sum_t \gamma^t w r_\psi(s,a)$  계산하여 Segment Utility 산출.
- Output: Preference Probability  $P_\psi$

3. Policy Forward (EQL):

- Input: State  $s$ , Weight  $w$
- Process: Q-Network  $\theta$  가 다목적 Q-Value  $Q(s, a, w)$  예측.
- Selection:  $\arg\max_a w Q(s, a, w)$ 를 통해 행동 선택.

## 4. 학습 메커니즘 및 최적화 (Optimization Dynamics)

역전파 역학 (Backpropagation Dynamics):

- Step 1: Reward Model Update (보상 학습)
- Principle: Cross-Entropy Loss 최소화.
- Purpose: 보상 모델  $r_\psi$  가 인간의 선호 판단과 일치하도록 조정.
- Data Example: 실제 선호가  $\sigma'$  인데 모델이  $\sigma$  를 선호한다고 예측(확률 0.8)했다면, 큰 Loss 발생  $\rightarrow \sigma'$ 의 보상을 높이고  $\sigma$ 의 보상을 낮추는 방향으로 Gradient 발생.

• Step 2: Relabeling (데이터 갱신)

- Principle: Off-policy Learning을 위한 데이터 재가공.
- Purpose: 과거에 수집된 궤적들의 보상 값을 현재 시점의 학습된 보상 모델  $r_\psi$  값으로 덮어쓰기(Relabeling). 이를 통해 정책 학습이 최신 보상 모델을 반영하도록 함.

• Step 3: Policy Update (정책 최적화 - EQL)

- Principle: Bellman Error Minimization.
- Equation:  $L(\theta) = |y - Q(s, a, w)|^2$ , where  $y = r_\psi + \gamma \max_{a'} Q(s', a', w)$ .
- Purpose: 학습된(가상의) 보상  $r_\psi$  를 최대화하는 행동을 학습.

알고리즘 구현 (Pseudocode Strategy on Pythonic Logic):

```
def train_pbmr1():
    # 1. Initialize Networks
    reward_model = RewardNet()
    policy = EQLAgent()
    buffer = PreferenceBuffer()

    for iteration in range(Max_Iter):
        # 2. Collect Data & Query Preference
        segments = collect_segments(policy)
        preferences = teacher.query(segments) # Human or Scripted feedback
        buffer.add(segments, preferences)

        # 3. Update Reward Model
        for _ in range(Grad_Steps):
            loss_r = compute_cross_entropy(reward_model, buffer.sample())
            optimizer_r.step(loss_r)

        # 4. Relabel & Update Policy
        replay_buffer.relabel_rewards(reward_model)
        for _ in range(Policy_Steps):
            loss_q = compute_bellman_error(policy, replay_buffer.sample())
            optimizer_q.step(loss_q)
```

## 5. 구현 상세 및 제약 사항 (Details & Constraints)

안정화 기법 (Stabilization Techniques):

- Critical Component: Weight Conditioned Network와 Relabeling.
- Justification: 가중치  $w$ 가 바뀔 때마다 별도의 모델을 학습하는 것은 비효율적임.  $w$ 를 입력으로 받는 하나의 네트워크로 모든 선호 분포를 커버함. 또한, 보상 모델이 변하기 때문에 과거 데이터의 보상 값을 주기적으로 갱신(Relabeling)하지 않으면 정책 학습이 수렴하지 않음.

시스템 한계 (System Limitations):

- Computational Complexity: 보상 모델 학습과 정책 학습이 번갈아 진행되므로, 단일 RL 대비 학습 시간이 증가함.
- Resource Constraints: 대량의 선호 데이터(Query)가 필요할 수 있음. 인간 피드백 비용이 높은 경우 병목이 될 수 있음.

## 6. 산업 적용 전략 (Industrial Application)

비즈니스 가치 (Business Value Proposition):

- Operational Efficiency: 복잡한 공정 제어(예: 반도체 제조, 화학 플랜트)에서 전문가가 일일이 보상 함수를 코딩할 필요 없이, "이 결과가 저것보다 좋다"는 피드백만으로 제어를 최적화할 수 있음.
- Use Case:
  - 스마트 그리드: 에너지 효율 vs 안정성 vs 비용 균형 조절.
  - 헬스케어: 환자의 고통 최소화 vs 치료 효과 극대화 (정량화하기 힘든 지표).
  - 개인화 추천: 사용자마다 다른 선호 가중치( $w$ )를 실시간으로 반영하여 추천 로직 변경.

## 7. 검증 및 누락 점검 (Validation Agent - Self-Correction)

Missing Information Check:

- [x] Core Equations: Bradley-Terry Model, Cross-Entropy Loss, EQL Objective 포함됨.
- [x] Key Algorithms: Reward Learning  $\rightarrow$  Relabeling  $\rightarrow$  Policy Update 루프 포함됨.
- [x] Theorems: 본문에는 자세한 증명 과정생략되었으나, "Theorem 4 (보상 모델 최적화와 파레토 최적화의 동치성)"의 의미는 1절과 2절에 반영됨.

Final Polish:

- 기술적 인과관계("Why & How")를 중심으로 서술되었으며, 모호한 표현을 배제함.